

Méthodes traditionnelles de NER :

1. Multilingual Named Entity Recognition for Medieval Charters Using Stacked Embeddings and BERT-based Models

- **Date** : juin 2022, LT4HALA Workshop @ LREC 2022, Marseille
- **Méthodologie** : Deux approches parallèles : (1) BiLSTM-CRF + stacked embeddings, combinant des vecteurs statiques FastText avec des vecteurs contextuels caractère par caractère (Flair), en entrée d'un modèle BiLSTM-CRF pour l'étiquetage de séquences ; (2) fine-tuning de modèles multilingues pré-entraînés : mBERT (multilingual BERT) et XLM-RoBERTa, ajustés sur le corpus HOME-Alcar pour une tâche de classification au niveau du token. Les types d'entités se limitent à PER (personnes) et LOC (lieux), avec un schéma d'annotation BIO. La méthode traite des défis spécifiques aux documents médiévaux : alternance codique (code-switching) latin/ancien français/ancien espagnol au sein d'un même texte, et forte instabilité orthographique des toponymes.
- **Données** : Corpus multilingue HOME-Alcar de chartes médiévales, composé de 17 cartulaires (11e–15e siècles), mêlant latin, ancien français et ancien espagnol, soit environ 2,3 millions de mots (7 576 chartes), issus de cinq collections diplomatiques (CBMA pour la Bourgogne, CODEA pour la Castille, etc.), avec alignement HTR sur les images manuscrites.
- **Résultats** : XLM-RoBERTa fine-tuné obtient le meilleur F1 global sur le jeu de test multilingue ; le BiLSTM-CRF atteint des performances proches des modèles BERT en contexte monolingue (latin) ; toutes les architectures voient leurs performances diminuer significativement en situation de code-switching ; le transfert croisé latin→français s'avère plus efficace que français→latin. Le modèle est disponible sur HuggingFace (précision auto-déclarée : 98,01).
- **Lien article** : <https://aclanthology.org/2022.lt4hala-1.17/>
- **Modèle (HuggingFace)** : <https://huggingface.co/magistermilitum/roberta-multilingual-medieval-ner>

Explication de l'approche 1 : FastText transforme chaque mot en un vecteur numérique pré-entraîné sur de larges corpus, capturant la sémantique lexicale (par exemple, « Cicero » et « Ciceronis » sont proches dans l'espace vectoriel). Flair lit le texte caractère par caractère plutôt que mot par mot, capturant ainsi les traits morphologiques (par exemple, le suffixe « -onis » comme marqueur du génitif latin). Les stacked embeddings consistent à concaténer ces deux représentations vectorielles, puis à les fournir en entrée au modèle BiLSTM-CRF : le BiLSTM (réseau de mémoire à long terme bidirectionnel) lit la phrase dans les deux sens pour capturer le contexte, tandis que le CRF assure la cohérence de la séquence d'étiquettes en sortie (empêchant par exemple qu'un B-PER soit immédiatement suivi d'un B-LOC, ce qui violerait les règles du schéma BIO).

Explication de l'approche 2 : mBERT et XLM-RoBERTa sont des modèles Transformer pré-entraînés sur des dizaines à des centaines de langues, dotés d'une capacité de compréhension multilingue. Le fine-tuning consiste à poursuivre l'entraînement de ces modèles sur les données annotées de HOME-Alcar, afin qu'ils apprennent à reconnaître les noms de personnes et de lieux spécifiques aux chartes médiévales.

Points transférables à notre projet : Si nous souhaitons par la suite automatiser l'annotation à l'aide d'un modèle, il faudra tenir compte du fait que les noms d'auteurs apparaissent sous forme de génitif latin — par exemple *Petri Comestoris*, *Gregorii PP.*, *Lactantii Firmiani* — et que le modèle devra être capable de reconnaître ces formes génitives comme des entités de type auteur, bien qu'elles diffèrent sensiblement de leur forme nominative standard (*Petrus Comestor*, *Gregorius*, *Lactantius Firmianus*).

Du point de vue des données et des objectifs de la tâche :

1. TEI-friendly annotation scheme for medieval named entities: a case on a Spanish medieval corpus

- **Date** : février 2021, Language Resources and Evaluation, vol. 55
- **Méthodologie** : Conception d'un schéma d'annotation manuelle, proposant un système de types d'entités compatible TEI-XML, conçu spécifiquement pour les documents médiévaux. Les types d'entités comprennent : Person (avec sous-attributs : titres, surnoms, relations familiales), Place (toponymes, noms géographiques, noms de bâtiments, etc.), Organization (institutions ecclésiastiques, institutions séculières), Date (dates absolues, dates relatives). Les directives d'annotation traitent les cas spécifiques aux documents médiévaux : noms au génitif latin, variantes orthographiques des toponymes, entités ambiguës non classifiables. Deux annotateurs ont travaillé de façon indépendante ; la cohérence inter-annotateurs est mesurée par le coefficient kappa.
- **Données** : Corpus numérisé de manuscrits médiévaux en espagnol, fourni par le Hispanic Seminary of Medieval Studies (HSMS), couvrant la période du 13e au 16e siècle et comprenant des chroniques, documents juridiques, textes narratifs, poésie et théâtre. Total : 26 200 mots, 3 974 entités (dont 2 054 annotées par un second annotateur pour le calcul de l'IAA).
- **Résultats** : Accord inter-annotateurs kappa = 0,802 (N = 2 054), jugé fiable. L'outil NER HisMeTag obtient un F1 de 0,63 à 0,89 sur ce corpus (selon la période du document). La contribution principale est la proposition d'un schéma d'annotation transférable à d'autres tâches NER sur documents médiévaux, et non la performance maximale d'un modèle.
- **Lien article** : <https://pmc.ncbi.nlm.nih.gov/articles/PMC8550670/>
- **GitHub** : <https://github.com/linhd-postdata/HisMetag> (contient l'outil d'annotation et le corpus)

Sur les directives d'annotation : Les directives d'annotation constituent un guide opérationnel indiquant aux annotateurs comment étiqueter chaque cas rencontré. Dans cet article, par exemple : *Alfonso* est étiqueté PER, *reino de Castilla* est étiqueté LOC ; la question se pose de savoir si un titre accompagné d'un nom (*Don Alfonso*) doit être étiqueté dans son ensemble comme PER ou seulement pour la partie nominale ; lorsqu'un terme peut désigner aussi bien un lieu qu'une institution, une règle de désambiguïsation est appliquée ; les variantes orthographiques (*Burgos* / *Burgis* / *Burgensis*) sont traitées de manière cohérente. Sans directives d'annotation, deux annotateurs produiraient des résultats incompatibles sur le même texte, rendant les données inutilisables.

Points méthodologiques transférables à notre projet :

1. Comment rédiger des directives d'annotation pour traiter les formes au génitif, les abréviations et les entités ambiguës
 2. Comment utiliser le coefficient kappa pour valider la cohérence inter-annotateurs
-

2. A Named Entity Recognition Model for Medieval Latin Charters

- **Date** : 2021, Digital Humanities Quarterly, vol. 15, n° 4
- **Auteurs** : Pierre Chastang, Sergio Torres Aguilar (votre directeur de stage), Xavier Tannier (Sorbonne Université)
- **Méthodologie** : Apprentissage supervisé, modèle CRF (Champ Aléatoire Conditionnel) pour l'étiquetage de séquences, combinant les traits suivants : traits morphologiques (préfixes, suffixes, majuscules), étiquetage morpho-syntaxique (POS), analyse en dépendances, traits lexicaux (gazetteers : listes d'autorité pour les noms de personnes et de lieux). Schéma d'annotation : PER et LOC au format BIO, avec traitement spécifique des particularités du latin médiéval (noms au génitif, abréviations, formules diplomatiques). Évaluation par validation croisée. Une étape d'entity linking est également implémentée, reliant les entités reconnues à des bases de connaissances externes.
- **Données** : CBMA (Corpus Burgundiae Medii Aevi), base de données de chartes et cartulaires médiévaux de Bourgogne, principalement issus de l'abbaye de Cluny, 10e–14e siècles, environ 5 300 documents (1,2 million de mots). Test de transfert croisé sur des chartes médiévales en espagnol (CODEA). L'annotation des entités a été réalisée par l'équipe de médiévistes du CBMA.
- **Résultats** : F1 élevé en validation croisée sur le corpus CBMA (meilleur pour les noms de personnes que pour les toponymes) ; le transfert croisé vers les chartes espagnoles entraîne une baisse de performance, mais le modèle reste exploitable ; la reconnaissance des toponymes est complexifiée par la forte divergence entre les formes médiévales et modernes, et par la faible couverture des gazetteers. L'article propose également un outil de démonstration en ligne (<https://entities-recognition.irht.cnrs.fr/>) à destination des chercheurs en humanités.
- **Lien article** : <http://www.digitalhumanities.org/dhq/vol/15/4/000574/000574.html>
- **Outil en ligne** : <https://entities-recognition.irht.cnrs.fr/>

Points directement réutilisables : L'outil en ligne <https://entities-recognition.irht.cnrs.fr/> permet de saisir directement le texte latin du catalogue et d'observer quels noms de personnes et de lieux sont automatiquement reconnus. Sur le plan méthodologique, la manière dont le modèle CRF traite les noms au génitif latin correspond directement à nos besoins ; l'ingénierie des traits développée pour des formes telles que *Petri* ou *Hugonis* est transférable à notre phase d'automatisation post-annotation.

Différence à noter : Leurs données sont des chartes diplomatiques à structure narrative, tandis que chaque entrée de notre catalogue est une notice de format fortement standardisé. Cela implique que leur modèle ne donnera pas des résultats optimaux sur nos données s'il est utilisé directement, mais il constitue une base de référence (baseline) tout à fait pertinente.

Test de l'outil sur notre données : Entrée testée : *221 Sacra Biblia, usque ad Malachiam inclusive. Cod. membranac. in folio atlantico, miro artificio elaboratus, et optime servatus Saec. XI quantivis pretii.*

Deux erreurs manifestes ont été observées. Premièrement, *Sacra Biblia* a été étiqueté I-PERS (nom de personne) : il s'agit en réalité d'un titre d'œuvre (ouvrage) ; l'outil l'a mal classé, probablement parce qu'il commence par une majuscule et constitue un nom propre, et que la catégorie « ouvrage » n'existe pas dans son système de types. Deuxièmement, *Saec* a été étiqueté B-PERS (début d'un nom de personne) : *Saec. XI* est l'abréviation de *Saeculum XI* (11e siècle), soit une information de date ; le modèle a confondu cette abréviation en majuscule avec un préfixe de nom de personne (à l'instar de *S.* pour *Sanctus*).

3. Evaluation of LLMs on Long-tail Entity Linking in Historical Documents

- **Date** : novembre 2024, EKAW 2024 Workshop (X-TAIL), Amsterdam
- **Méthodologie** : Évaluation des capacités des LLM dans des scénarios d'entity linking (EL) à longue traîne sur des documents historiques. Pipeline en deux étapes : (1) détection des mentions d'entités par un modèle BERT en phase NER ; (2) EL comparant trois stratégies : GPT-3.5-turbo-instruct, LLama-3-8B-instruct, LLama-3-70B (versions instruct) contre ReLiK (framework EL état de l'art, basé sur une architecture Retriever-Reader). Le titre de la page Wikipedia est utilisé comme identifiant cible plutôt que le QID Wikidata (les expériences montrent que les LLM hallucinent massivement les QIDs : précision de GPT-3.5 inférieure à 1 %). L'évaluation porte spécifiquement sur les entités de longue traîne (entités rares dans les données d'entraînement et les bases de connaissances).

Pertinence pour notre projet : De nombreux auteurs et œuvres présents dans notre catalogue constituent précisément des entités de longue traîne. Par exemple : RUINUS GERMANUS FELIX (entrée 252) est quasi absent de Wikidata ; HIEREMIAS DE MONTAGNONE (entrée 250) est très peu connu ; GERHARDUS DE RENE MONACHUS (Ricc. 306 dans le JSON) est totalement obscur. Les méthodes d'EL traditionnelles (basées sur la correspondance de chaînes ou la similarité vectorielle) échouent souvent sur ce type d'entités, précisément parce qu'elles sont absentes ou très peu représentées dans les bases de connaissances. La conclusion de cet article est que les LLM surpassent les méthodes traditionnelles sur l'EL à longue traîne, car ils ont été exposés à de vastes corpus de documents historiques lors de leur pré-entraînement et disposent d'une certaine connaissance de ces entités rares, même en l'absence d'une entrée complète dans Wikidata.

- **Données** : MHERCL v0.1 (Musical Heritage named Entities Recognition, Classification and Linking), ensemble de phrases extraites de périodiques historiques du domaine musical et annotées manuellement, contenant de nombreuses entités spécifiques au domaine sous-représentées ou absentes de Wikidata (compositeurs, luthiers, éditeurs musicaux et autres personnalités historiques).
- **Résultats** : Les LLM surpassent le modèle supervisé ReLiK sur l'EL à longue traîne ; LLama-3-70B obtient les meilleures performances globales ; les LLM bénéficient de

leur vaste connaissance pré-entraînée pour les entités rares, mais échouent encore sur les entités totalement absentes de leurs données d'entraînement ; le problème des hallucinations (en particulier pour la génération de QIDs Wikidata) est contourné en utilisant les titres Wikipedia comme identifiants cibles.

- **Lien article** : <https://arxiv.org/abs/2505.03473>
- **GitHub** : Pas de dépôt de code identifié ; pour le jeu de données MHERCL, voir <https://link.springer.com/article/10.1007/s10462-024-11102-9>

Application à notre pipeline d'entity linking : Notre pipeline actuel est le suivant : span annoté dans le texte original → consultation du dictionnaire pour restituer la forme nominative → appel à l'API VIAF/Wikidata. Il est possible d'y intégrer une étape LLM intermédiaire : span annoté → LLM pour la restitution et la normalisation au nominatif → appel à l'API VIAF/Wikidata → retour de l'URI. Lors de l'appel à l'API, il ne faut pas demander au LLM de générer directement un QID, mais plutôt de produire la forme standard du nom (par exemple *Petrus Comestor*) ; c'est ensuite l'API qui retourne le QID fiable. Pour les entités totalement inconnues (comme GERHARDUS DE RENE MONACHUS), le LLM peut lui-même ne pas disposer de l'information ; dans ce cas, le résultat NIL (entité absente de la base de connaissances) constitue une annotation valide, attestant du caractère véritablement de longue traîne de l'entité concernée.

Sur la question des QIDs et des titres Wikipedia : Dans Wikidata, chaque entité possède un identifiant unique de la forme Q + chiffre, appelé QID (par exemple, Cicéron → Q1541, Augustin → Q8018). Le titre Wikipedia désigne simplement le nom de la page correspondante (par exemple *Cicero, Augustine of Hippo*). Les LLM hallucinent massivement les QIDs car ces identifiants sont de pures séquences numériques sans logique linguistique : le modèle n'a pas appris de manière systématique la correspondance entre un nom et son QID, et génère donc des identifiants plausibles mais faux. En revanche, les titres Wikipedia sont du texte naturel que les LLM ont rencontré en abondance lors du pré-entraînement ; ils savent par exemple que *Gregorii PP.* correspond à la page *Gregory I* sur Wikipedia, ce qui réduit considérablement le taux d'hallucination.